Asymptotic Statistics Assignment 1
(Date limite : le 12 octobre)

Wen, Zehai

Temps de compilation : 2026-06-21 10:22:34-04:00

Remarque Toutes les références dans ce document sont tirées de notre note de cours ou des tables des distributions si le contraire n'est pas explicitement mentionné.

Exercice 1

Soit $X = (X_1, \cdots, X_n)$ un échantillon de P_θ = Bernoulli(θ). Le paramètre $\theta \in [0,1]$ est inconnu. Fixer un niveau $\alpha \in (0,1)$. On écrit $\overline{X} = \frac{1}{n}\sum_{i=1}^n X_i$ et $c(\theta)$ pour la plus petite nombre $k \in \{0, \cdots, n\}$ telle que $P_\theta\{X_1 + \cdots X_n \leqslant k\} \geqslant 1-\alpha$. On construit trois régions de confiances suivantes pour θ :

$$R_1(X) = \left\{\theta \in [0,1] \mid \overline{X} - \theta \leqslant z_\alpha \sqrt{\frac{\theta(1-\theta)}{n}}\right\}$$

$$R_2(X) = \left\{\theta \in [0,1] \mid \overline{X} - \theta \leqslant z_\alpha \sqrt{\frac{\overline{X}(1-\overline{X})}{n}}\right\}$$

$$R_3(X) = \left\{\theta \in [0,1] \mid n\overline{X} \leqslant c(\theta)\right\}$$

Ici $z_\alpha \in \mathbb{R}$ est choisie telle que $P\{Z \leqslant z_\alpha\} = 1-\alpha$, où Z est une variable aléatoire qui suit la loi normale centrée réduite.

Complétez les tâches suivantes :

1. Tracez $c(\theta)$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$.
2. Démontrez que $\frac{1}{n}\sum_{i=1}^n (x_i - \overline{x})^2 = \overline{x}(1-\overline{x})$ si $x_i \in \{0,1\}$ pour $i \in \{1, \cdots, n\}$. Ici $\overline{x} = \frac{1}{n}\sum_{i=1}^n x_i$.
3. Étant donné X, résolvez pour θ dans $R_1(X)$, $R_2(X)$ et $R_3(X)$. Concluez que toutes les trois régions sont intervalles.
4. Pour $k \in \{1,2,3\}$, calculez et tracez $P_\theta\{\theta \in R_k\}$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$.

Utilisez $n = 30$, $\alpha = 0.1$ et $M = 1000$ pour toutes les simulations.

Solution On fait les démonstrations avant les simulations. D'abord, soit $x_i \in \{0,1\}$ pour $i \in \{1, \cdots, n\}$. On a $x_i^2 = x_i$ pour tout i et :

$$\frac{1}{n}\sum_{i=1}^n (x_i - \overline{x})^2 = \frac{1}{n}\sum_{i=1}^n (x_i^2 - 2x_i\overline{x} + \overline{x}^2) = \overline{x} - \overline{x}^2 = \overline{x}(1-\overline{x})$$

Étant observé $X = (x_1, \cdots, x_n)$, on donne les formes explicites pour les trois régions. $R_1(X)$ donne une inégalité quadratique. Il faut résoudre d'abord $\overline{x} - \theta = \frac{z_\alpha}{\sqrt{n}}\sqrt{\theta(1-\theta)}$. Les racines sont :

$$\theta = \frac{2n\overline{x} + z_\alpha^2 \pm \sqrt{z_\alpha^4 + 4nz_\alpha^2\overline{x} - 4nz_\alpha^2\overline{x}^2}}{2(n + z_\alpha^2)}$$

L'existence de ces racines dépend sur la valeur de $\overline{x}$, alors un autre quadratique. Les racines sont :

$$\overline{x} = \frac{n \pm \sqrt{n^2 + z_\alpha^2 n}}{2n}$$

Alors, les racines de θ existe si $\overline{x} \in \left[\frac{n-\sqrt{n^2+z_\alpha^2 n}}{2n}, \frac{n+\sqrt{n^2+z_\alpha^2 n}}{2n}\right] \supset [0,1]$. Un regard aux graphes des fonctions $\overline{x}-\theta$ et $\frac{z_\alpha}{\sqrt{n}}\sqrt{\theta(1-\theta)}$ montre que ces deux fonctions se croise deux fois si et seulement si $\overline{x} \in \left[1, \frac{n+\sqrt{n^2+z_\alpha^2 n}}{2n}\right]$, et se croise exactement une fois quand $\theta = \frac{2n\overline{x}+z_\alpha^2-\sqrt{z_\alpha^4+4nz_\alpha^2\overline{x}-4nz_\alpha^2\overline{x}^2}}{2(n+z_\alpha^2)}$ sinon. Alors :

$$R_1(X) = \begin{cases} [0,1] & \overline{X} \leqslant 0 \\ \left[\frac{2n\overline{x}+z_\alpha^2-\sqrt{z_\alpha^4+4nz_\alpha^2\overline{x}-4nz_\alpha^2\overline{x}^2}}{2(n+z_\alpha^2)}, 1\right] & \overline{X} \in [0,1] \\ \left[\frac{2n\overline{x}+z_\alpha^2-\sqrt{z_\alpha^4+4nz_\alpha^2\overline{x}-4nz_\alpha^2\overline{x}^2}}{2(n+z_\alpha^2)}, \frac{2n\overline{x}+z_\alpha^2+\sqrt{z_\alpha^4+4nz_\alpha^2\overline{x}-4nz_\alpha^2\overline{x}^2}}{2(n+z_\alpha^2)}\right] & \overline{X} \in \left[1, \frac{n+\sqrt{n^2+z_\alpha^2 n}}{2n}\right] \\ \emptyset & \overline{X} > \frac{n+\sqrt{n^2+z_\alpha^2 n}}{2n} \end{cases}$$

Ensuite, $R_2(X)$ est bien définie pour seulement $\overline{x} \in [0,1]$. Si $\overline{x} \in [0,1]$, on a :

$$R_2(X) = \left[\max\left\{0, \overline{X} - z_\alpha\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}\right\}, 1\right]$$

On se concentre, à partir de maintenant, sur $R_3(X)$. Fixer un niveau $\alpha \in (0,1)$. Afin de trouver et invertir $c(\theta)$, on doit représenter cette définition discrète par une fonction spéciale. On utilise la fonction bêta incomplète régularisée :

$$I_x(a,b) = \frac{B(x;a,b)}{B(a,b)} = \frac{\int_0^x t^{a-1}(1-t)^{b-1}dt}{\int_0^1 t^{a-1}(1-t)^{b-1}dt}$$

Ici $x \in [0,1]$ et $a, b > 0$. Pour a et b fixés, $I_x(a,b)$ est une fonction continue et strictement croissante de x. On a alors une inverse continue et strictement croissante $I_y^{-1}(a,b)$ pour tout y dans l'image telle que $y = I_{I_y^{-1}(a,b)}(a,b)$. La somme $X_1 + \cdots + X_n$ suit la loi binomiale $B(n,\theta)$. Utilisant la fonction bêta incomplète régularisée, on peut représenter la fonction de répartition de cette distribution.

Pour tout $k \in \{0, \cdots, n\}$, on a :

$$P_\theta\left\{X_1 + \cdots + X_n \leqslant k\right\} = \sum_{m=0}^{k}\binom{n}{m}\theta^m(1-\theta)^{n-m} = I_{1-\theta}(n-k, k+1)$$

On remarque que cette formule démontre que $I_\theta(n-k,k+1)$ est croissante en nombres entiers k pour tout $\theta \in [0,1]$ fixé. On démontre un lemme, qui va être utile plus tard.

Lemme 1. Fixer un $v \in (0,1)$. La fonction $I_v^{-1}(n-k,k+1)$ est décroissant en nombres entiers $k \in \{0, \cdots, n\}$.

Proof. Soit k_1 et $k_2 \in \{0, \cdots, n\}$ telle que $k_1 \leqslant k_2$. Écrire $y_1 = I_v^{-1}(n-k_1, k_1+1)$ et $y_2 = I_v^{-1}(n-k_2, k_2+1)$. En raison de croissance monotone de k :

$$I_{y_2}(n-k_2,k_2+1) = v = I_{y_1}(n-k_1,k_1+1) \leqslant I_{y_1}(n-k_2,k_2+1)$$

La croissance monotone de x dans les fonctions $I_x(a,b)$ implique que $y_1 \geqslant y_2$. □

Retournons au problème principal. Si $y \leqslant 0$, on a $c(\theta) \geqslant y$ pour tout $\theta \in [0,1]$. Si $y > n$, on a $c(\theta) \geqslant y$ pour aucun $\theta \in [0,1]$. Si $y \in \{1, \cdots, n\}$, on a $c(\theta) \geqslant y$ si et seulement si $I_{1-\theta}(n-k,k+1) \geqslant 1-\alpha$ pour tout $k \in \{y, y+1, \cdots, n\}$ et $I_{1-\theta}(n-y+1,y) < 1-\alpha$. Si on utilise la première condition avec $k = y$, on a, selon la croissance monotone de la fonction inverse :

$$\theta \leqslant 1 - I_{1-\alpha}^{-1}(n-y, y+1)$$

Le lemme montre que cette borne supérieure est la plus petite borne supérieure possible. Similairement, on a :

$$\theta > 1 - I_{1-\alpha}^{-1}(n-y+1, y)$$

Finalement, l'observation $\{\theta \in [0,1] \mid c(\theta) \geqslant y\} = \{\theta \in [0,1] \mid c(\theta) \geqslant \lceil y \rceil\}$ pour tout $y \in \mathbb{R}$ va résoudre le cas général. On conclut que :

$$R_3(X) = \begin{cases} [0,1] & \overline{X} \leqslant 0 \\ \emptyset & \overline{X} > 1 \\ \left(1 - I_{1-\alpha}^{-1}(n - \lceil n\overline{X} \rceil + 1, \lceil n\overline{X} \rceil), 1 - I_{1-\alpha}^{-1}(n - \lceil n\overline{X} \rceil, \lceil n\overline{X} \rceil + 1)\right] & \text{sinon} \end{cases}$$

On voudrait aussi calculer les probabilités de couverture exacte $P_\theta\{\theta \in R_k(X)\}$ pour les trois régions. Écrire, pour tout $x \in \mathbb{R}$, que $h(x) = \chi_{[0,n+1)}(x)\lfloor x \rfloor + n\chi_{[n+1,\infty)}(x)$. Il est immédiat que :

$$P_\theta\{\theta \in R_1(X)\} = \sum_{i=0}^{h\left(n\theta + z_\alpha\sqrt{n\theta(1-\theta)}\right)} \binom{n}{i}\theta^i(1-\theta)^{n-i}; \quad P_\theta\{\theta \in R_3(X)\} = \sum_{i=0}^{c(\theta)} \binom{n}{i}\theta^i(1-\theta)^{n-i}$$

Pour trouver $P_\theta\{\theta \in R_2(X)\}$, il faut d'abord résoudre l'équation $\overline{X} - \theta = z_\alpha\sqrt{\frac{\overline{X}(1-\overline{X})}{n}}$. La solution est :

$$\overline{x} = \frac{2n\theta + z_\alpha^2 \pm \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n+z_\alpha^2)}$$

Comme $\theta \in [0,1]$, cette solution existe toujours. Un regard aux graphes des fonctions $\overline{x} - \theta$ et $z_\alpha\sqrt{\frac{\overline{x}(1-\overline{x})}{n}}$ montre que ces deux fonctions se croise deux fois si et seulement si $\theta = 0$ et se croise exactement une fois à $\overline{x} = \frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n+z_\alpha^2)}$ sinon. Alors, $\theta \in R_2(X)$ si et seulement si $\overline{X} \in \left[0, \frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n+z_\alpha^2)}\right]$. On obtient que :

$$P_\theta\{\theta \in R_2(X)\} = \sum_{i=0}^{h\left(\frac{2n\theta + z_\alpha^2 + \sqrt{z_\alpha^4 + 4nz_\alpha^2\theta - 4nz_\alpha^2\theta^2}}{2(n+z_\alpha^2)}\right)} \binom{n}{i}\theta^i(1-\theta)^{n-i}$$

Les démonstrations sont complètes. On trace des fonctions importantes. D'abord, on trace $c(\theta)$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^M$.

```
library(ggplot2)

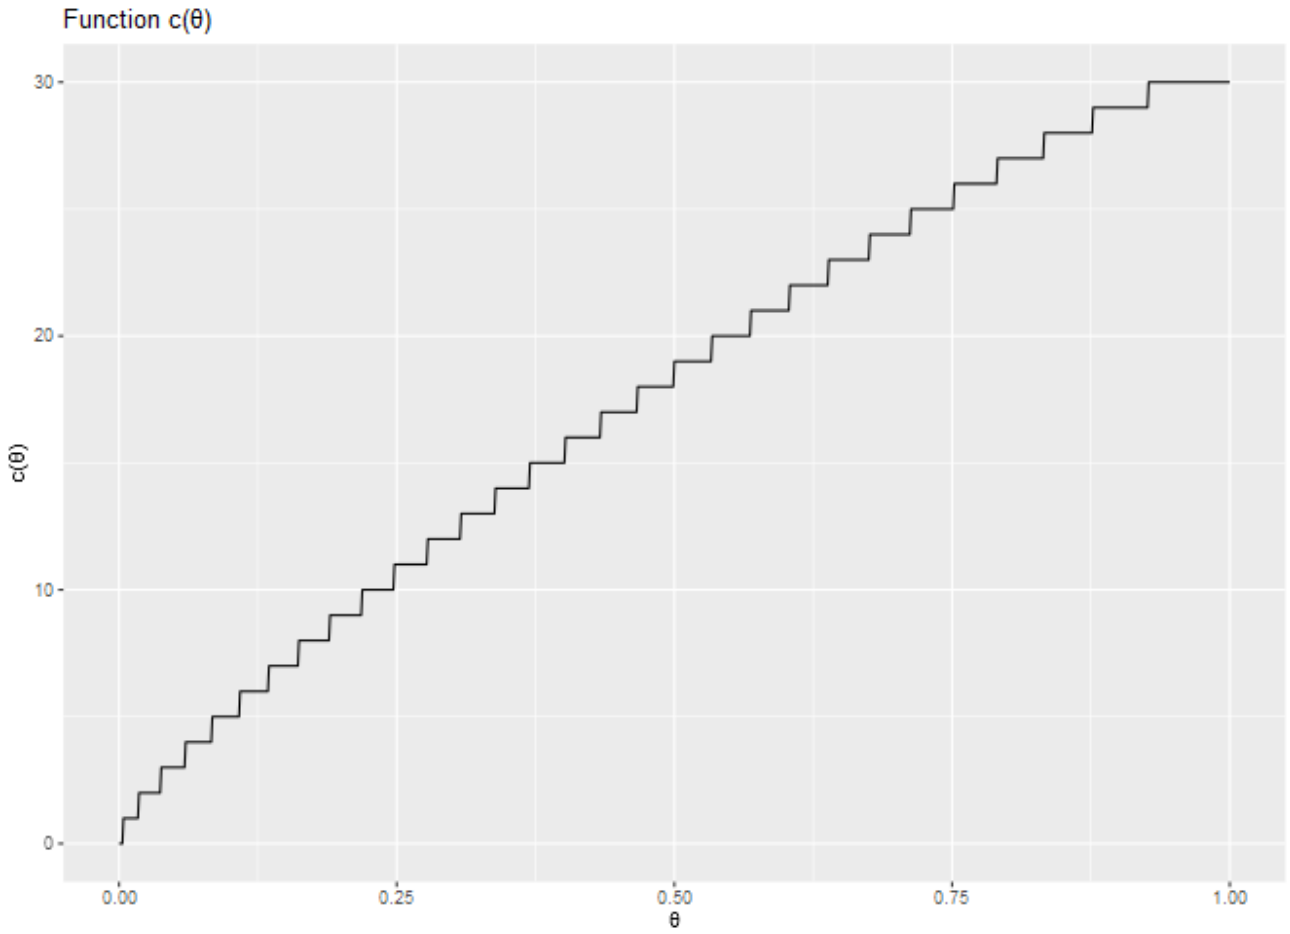
n <- 30
alpha <- 0.1
M <- 1000
theta_values <- seq(0, 1, length.out = M+1)

c_theta <- function(theta) {
  for (k in 0:n) {
    if (pbinom(k, n, theta) >= 1 - alpha) {
      return(k)
    }
```

```
  }
  return(n)
}

c_values <- sapply(theta_values, c_theta)
p <- ggplot(data.frame(theta = theta_values, c = c_values), aes(x = theta, y =
    c)) +
  geom_line() +
show(p)
```

Le résultat est :



Ensuite, on trace $P_\theta\{\theta \in R_k\}$ pour les $\theta \in \{\frac{i}{M}\}_{i=0}^{M}$ et pour chaque $k \in \{1,2,3\}$. Le code R le plus inefficace est comme suivant :

```
h <- function(num){
    if (num >= n) {
       return (n)
    }
    else {
        return(floor(num))
    }
}

R_1_borne <- function(theta){
    return (h(n*theta + qnorm(1-alpha)*sqrt(n*theta*(1-theta))))
```

```
}

R_1_bornes <- sapply(theta_values, R_1_borne)

R_3_borne <- function(theta){
   z_alpha <- qnorm(1-alpha)
   return (h(2*n*theta + z_alpha^2 + sqrt(z_alpha^4 + 4*n*theta*(z_alpha^2)-
      4*n*(theta*z_alpha)^2)/(2*n+2*z_alpha^2)))
}

R_3_bornes <- sapply(theta_values, R_3_borne)

prob_couverture <- matrix(0, nrow = 3, ncol = length(theta_values))
for (i in seq_along(theta_values)){
   theta <- theta_values[i]
   for (j in 0: R_1_bornes[i]){
      prob_couverture[1, i] <- prob_couverture[1, i] + dbinom(j, n, theta)
   }
   for (j in 0: c_values[i]){
      prob_couverture[2, i] <- prob_couverture[2, i] + dbinom(j, n, theta)
   }
   for (j in 0: R_3_bornes[i]){
      prob_couverture[3, i] <- prob_couverture[3, i] + dbinom(j, n, theta)
   }
}

data_to_plot <- data.frame(
  Theta = rep(theta_values, times = 3),
  Coverage = c(prob_couverture[1, ], prob_couverture[2, ], prob_couverture[3, ]),
  Interval = rep(c("R1", "R2", "R3"), each = length(theta_values))
)

p <- ggplot(data_to_plot, aes(x = Theta, y = Coverage, color = Interval)) +
  geom_line() +
  labs(title = "Probabilité de couverture exacte pour différents intervalles de
     confiance",
       x = "", y = "Probabilité de couverture exacte") +
  theme_minimal() + labs(color = " ") +
  theme(legend.position = "top")+
  geom_abline(intercept = 0.9, slope = 0, color="black")

show(p)
```

On fait aussi une simulation générant 500 fois jeu de données pour chaque $\theta \in \{\frac{i}{M}\}_{i=0}^{M}$.

```
check_in_R_1 <- function(theta, x_bar){
  if (x_bar - theta <= qnorm(1 - alpha / 2)*sqrt(theta*(1-theta)/n)){
    return (1)
    }
  else{
    return(0)}
}
```

```
check_in_R_2 <- function(theta, x_bar){
  if (x_bar - theta <= qnorm(1 - alpha / 2)*sqrt(x_bar*(1-x_bar)/n)){
    return (1)
    }
  else{
    return(0)}
}

check_in_R_3 <- function(theta, x_bar){
  if (n*x_bar <= c_theta(theta)){
    return (1)
    }
  else{
    return(0)}
}

simulation <- function(num_simulations = 500){
  coverage_prob <- matrix(0, nrow = 3, ncol = length(theta_values))
  for (i in seq_along(theta_values)){
    theta <- theta_values[i]
    coverage <- c(R1 = 0, R2 = 0, R3 = 0)
    for (sim in 1:num_simulations) {
      samples <- rbinom(n, size = 1, prob = theta)
      x_bar <- mean(samples)
      coverage["R1"] <- coverage["R1"] + check_in_R_1(theta, x_bar)
      coverage["R2"] <- coverage["R2"] + check_in_R_2(theta, x_bar)
      coverage["R3"] <- coverage["R3"] + check_in_R_3(theta, x_bar)
    }
  coverage_prob[1, i] <- coverage["R1"] / num_simulations
  coverage_prob[2, i] <- coverage["R2"] / num_simulations
  coverage_prob[3, i] <- coverage["R3"] / num_simulations
  }
  return(coverage_prob)
}

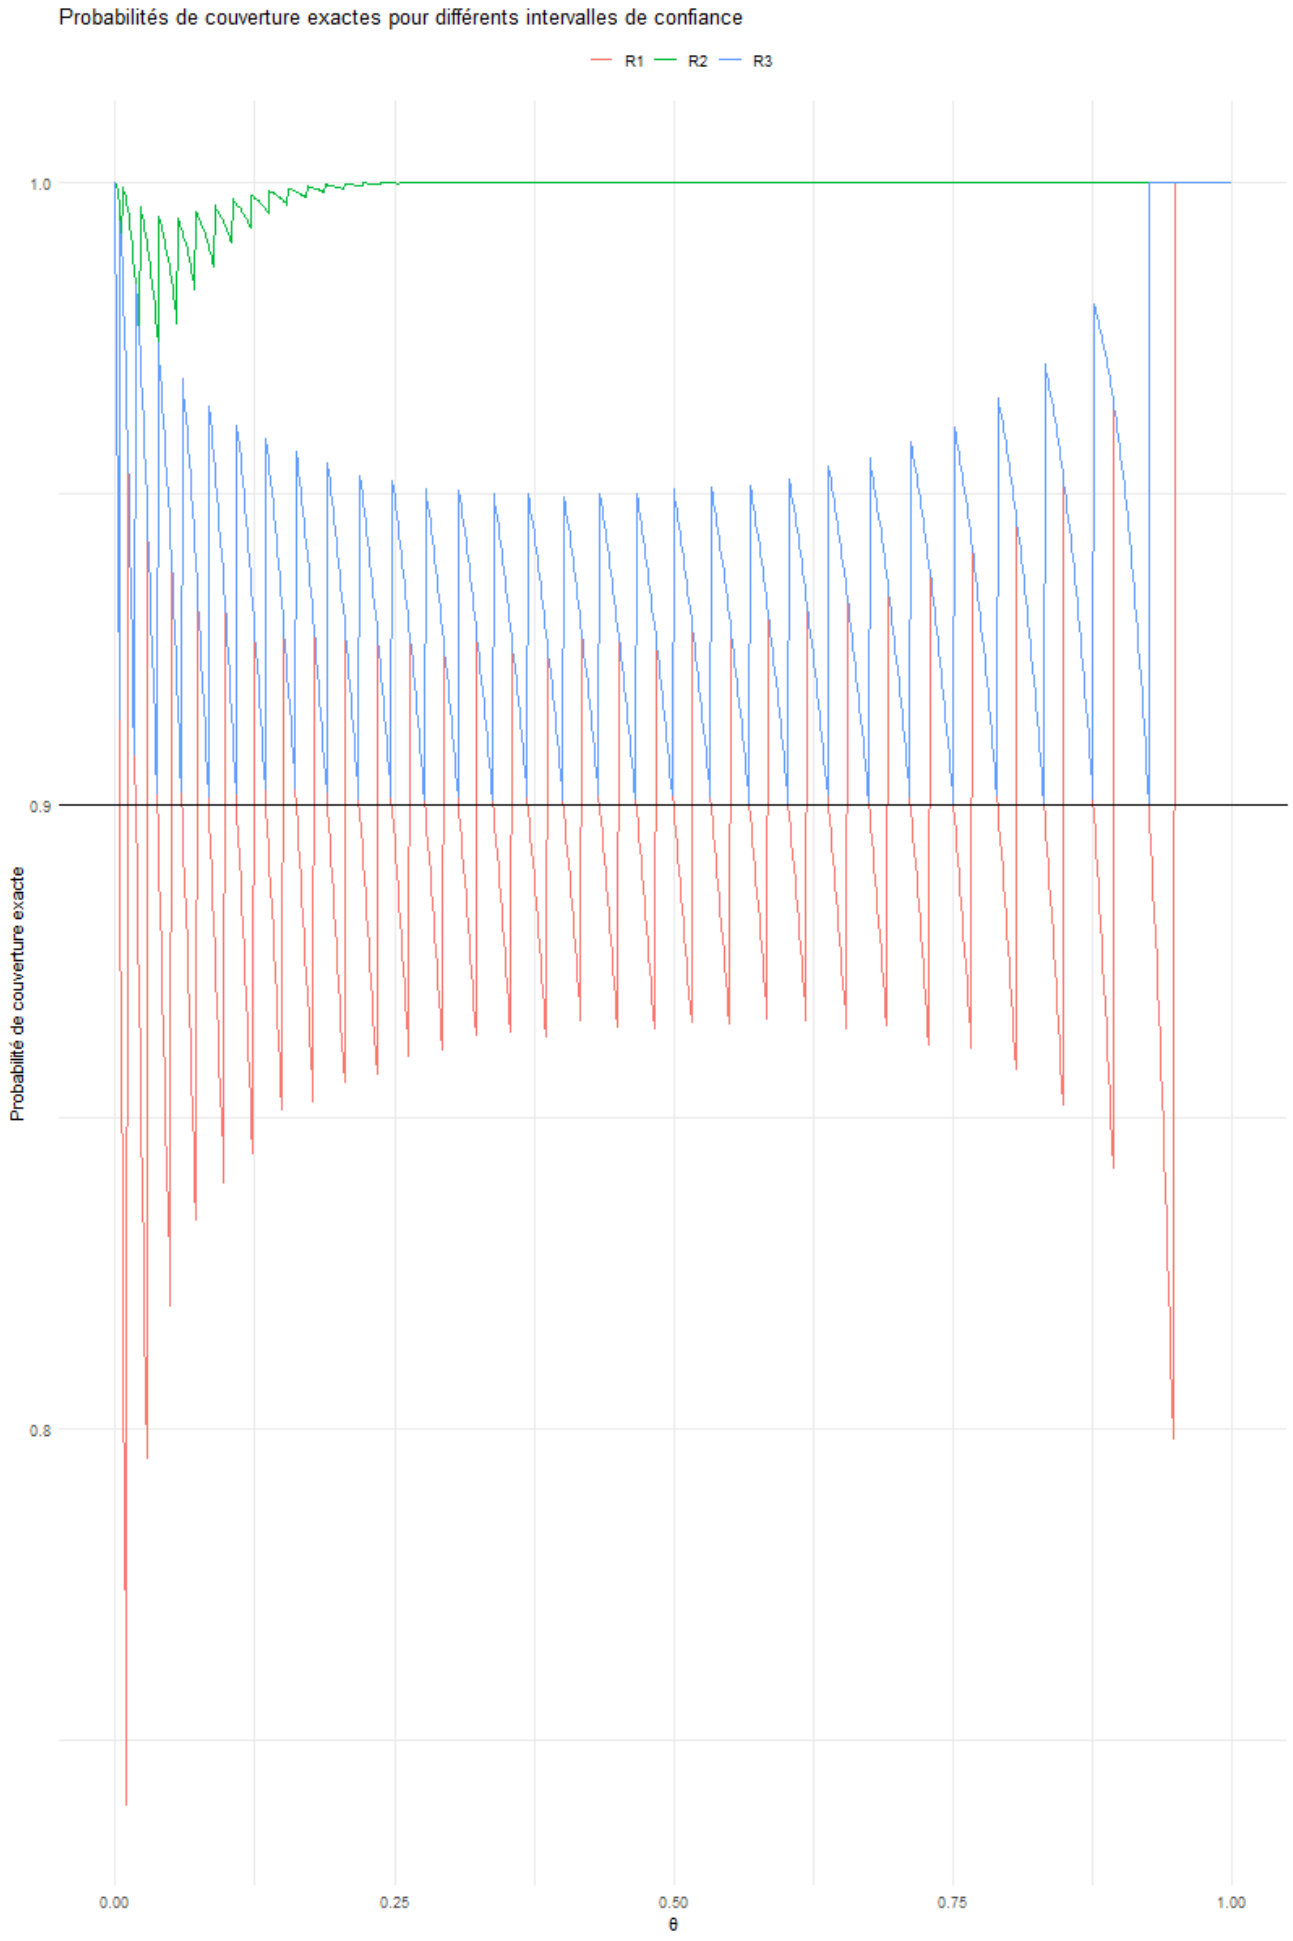
coverage <- simulation()

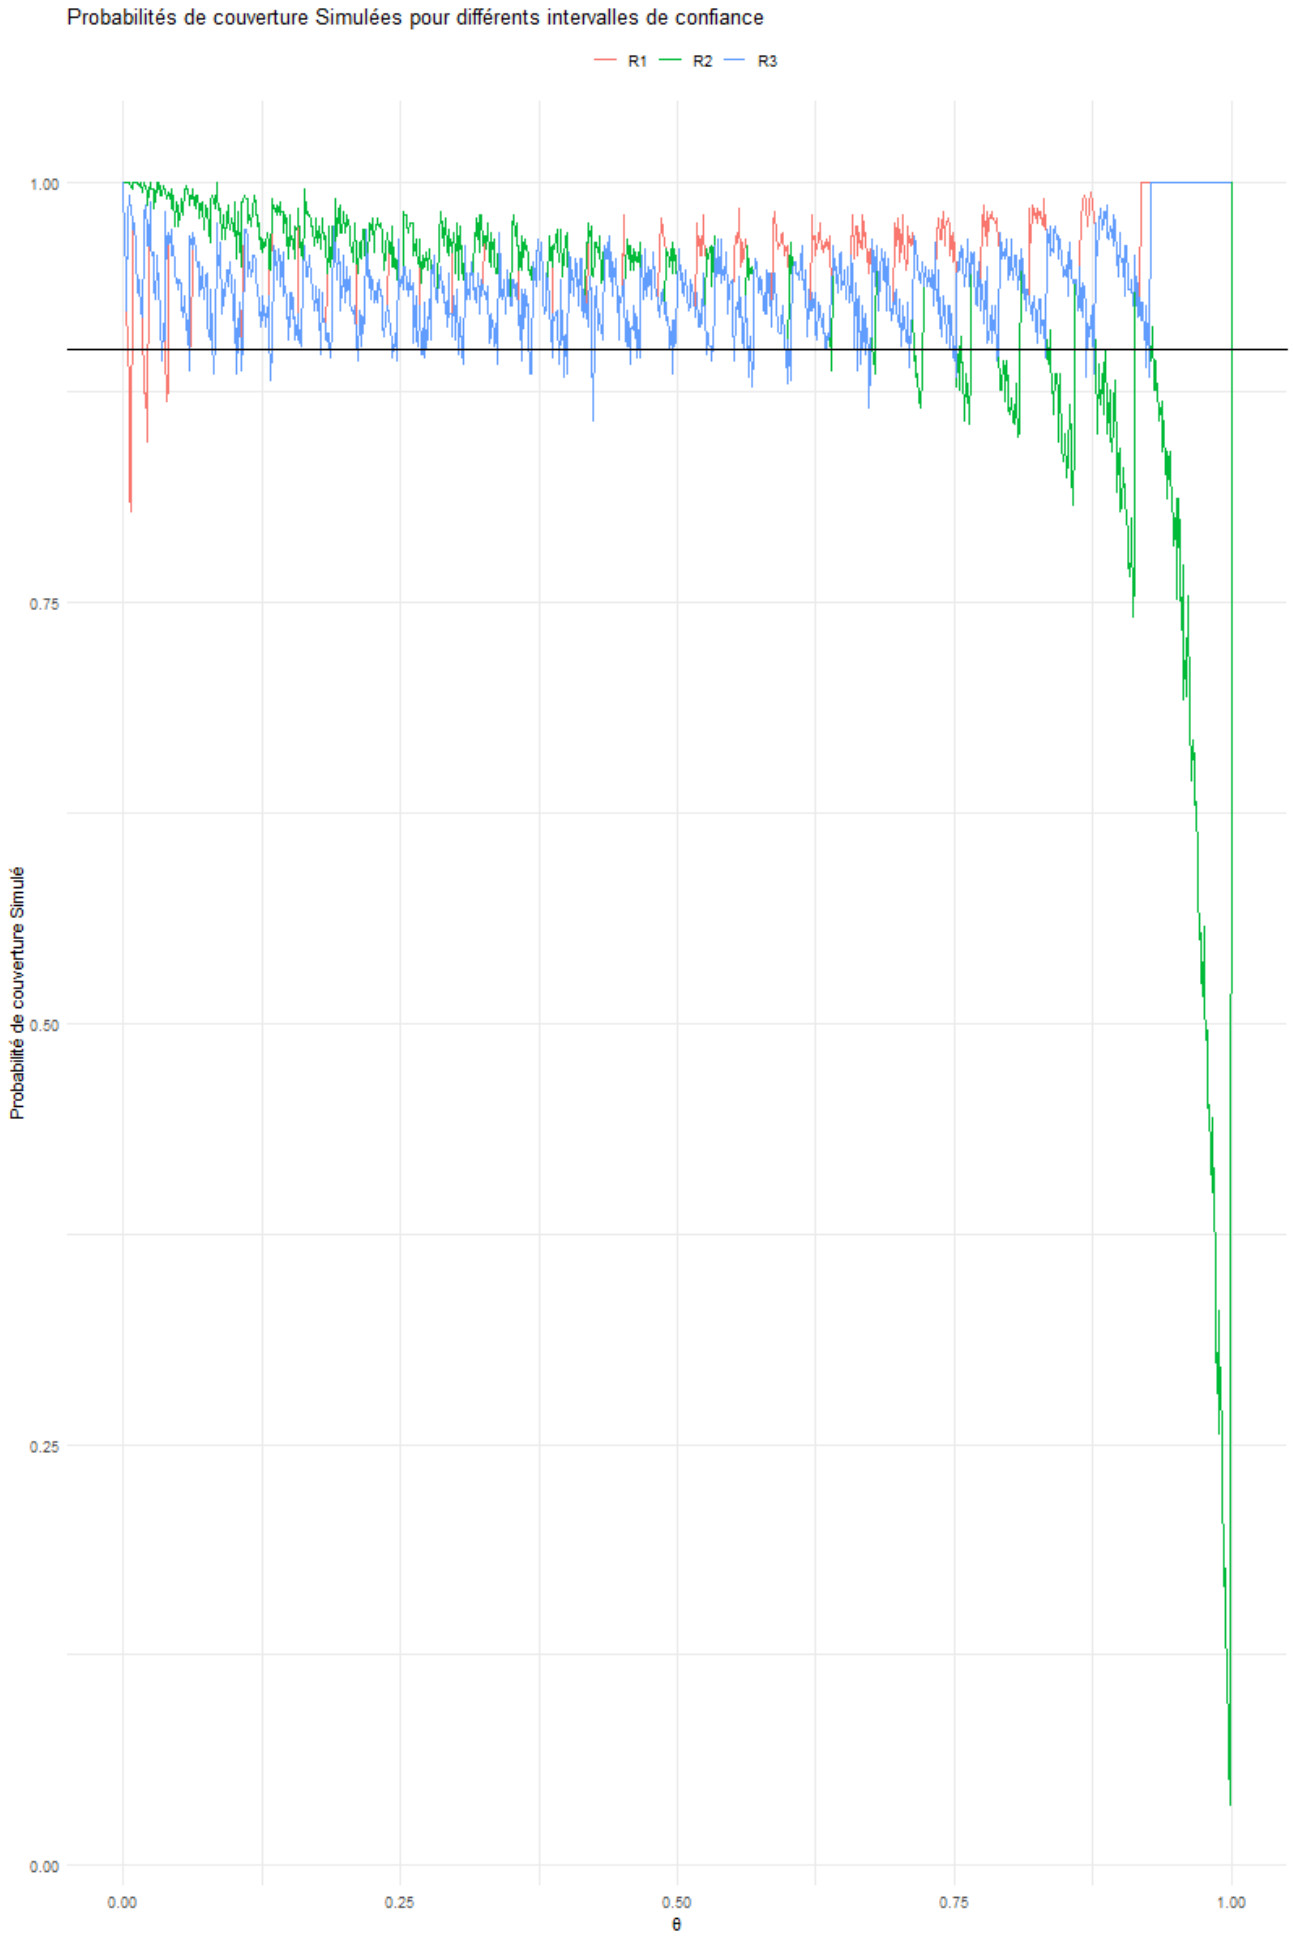
data_to_plot <- data.frame(
  Theta = rep(theta_values, times = 3),
  Coverage = c(coverage[1, ], coverage[2, ], coverage[3, ]),
  Interval = rep(c("R1", "R2", "R3"), each = length(theta_values))
)

p <- ggplot(data_to_plot, aes(x = Theta, y = Coverage, color = Interval)) +
  geom_line() +
  labs(title = "Probabilités de couverture Simulées pour différents intervalles de
     confiance",
       x = ", y = "Probabilité de couverture Simulé") +
  theme_minimal() + labs(color = " ") +
  theme(legend.position = "top")+
  geom_abline(intercept = 0.9, slope = 0, color="black")

show(p)
```

Les résultats sont :


Probabilités de couverture exactes pour différents intervalles de confiance
R1
R2
R3
1.0
0.9
0.8
Probabilité de couverture exacte
0.00
0.25
0.50
0.75
1.00
θ


Probabilités de couverture Simulées pour différents intervalles de confiance
R1
R2
R3
1.00
0.75
0.50
0.25
0.00
Probabilité de couverture Simulé
0.00
0.25
0.50
0.75
1.00
θ

Alors, dans la théorie ou dans la simulation, parmi les valeurs de θ, c'est plus souvent que R_1 ou R_3 est le plus proche de niveau de confiance nominale $1-\alpha$. Le phénomène de zigzag est aussi observé dans la simulation. ////

Exercice 2

Soit X_1 et X_2 un échantillon de taille 2 de $P_\theta = \text{Uniform}(0,\theta)$. Le paramètre $\theta > 0$ est inconnu. Écrire $Y = \frac{X_1+X_2}{2}$. Étant observé X_1 et X_2, on construit un intervalle de confiance pour θ de niveau $1-\alpha = 0.9$ sous la forme $[aY, bY]$ pour $a, b \in \mathbb{R}$. Trouvez a et b telle que la longueur de l'intervalle soit minimale.

Solution Toutes les densités sont par rapport à la mesure de Lebesgue en $\mathbb{R}$. Évidement, $\frac{1}{\theta}(X_1+X_2)$ est une somme de deux variables aléatoires indépendantes de loi $\text{Uniform}(0,1)$. Sa densité h est donnée par :

$$h(z) = \int_{\mathbb{R}} \chi_{(0,1)}(x)\chi_{(0,1)}(x-z)dx = m((z-1,z)\cap(0,1)) = z\chi_{(0,1)}(z) + (2-z)\chi_{(1,2)}(z)$$

Écrire f pour la densité de $\frac{\theta}{Y}$. Alors :

$$f(z) = \frac{4}{z^3}\chi_{(2,\infty)}(z) + \left(\frac{4}{z^2} - \frac{4}{z^3}\right)\chi_{(1,2)}(z)$$

Supposons que $P_\theta\{\theta \in [aY, bY]\} = 1-\alpha$ pour des nombres $a, b \in \mathbb{R}$, où $\alpha = 0.1$. Comme :

$$\int_2^\infty \frac{4}{z^3}dz = \int_1^2 \left(\frac{4}{z^2} - \frac{4}{z^3}\right)dz = \frac{1}{2}$$

Il faut minimiser $b-a$ pour $1 \leqslant a \leqslant 2 \leqslant b$ sous la contrainte :

$$1-\alpha = \int_a^b f(z)dz = \int_a^2 \left(\frac{4}{z^2} - \frac{4}{z^3}\right)dz + \int_2^b \frac{4}{z^3}dz$$

Après de résoudre des intégraux, on obtient la contrainte simplifiée :

$$\frac{4}{a} - \frac{2}{a^2} - 2 + \alpha - \frac{2}{b^2} = 0$$

On multiplie a^2b^2 des deux côtés et on obtient :

$$[(\alpha-2)a^2 + 4a - 2]b^2 = 2a^2$$

Comme $(\alpha-2)a^2+4a-2 > 0$ quand $a \in (\frac{2-\sqrt{2\alpha}}{2-\alpha}, \frac{2+\sqrt{2\alpha}}{2-\alpha})$, on réduit la contrainte de a à $[1,2]\cap(\frac{2-\sqrt{2\alpha}}{2-\alpha}, \frac{2+\sqrt{2\alpha}}{2-\alpha})$. Quand $\alpha = 0.1$, cela donne effectivement $a \in [1, 1.288007156)$. Si a est dans cet intervalle, on a :

$$b = a\sqrt{\frac{2}{(\alpha-2)a^2 + 4a - 2}}$$

On définit une fonction $g : [1,2]\cap(\frac{2-\sqrt{2\alpha}}{2-\alpha}, \frac{2+\sqrt{2\alpha}}{2-\alpha}) \to \mathbb{R}$ par :

$$g(a) = a\sqrt{\frac{2}{(\alpha-2)a^2 + 4a - 2}} - a$$

Comme g est continue, soit a_0 le minimum de g. L'intervalle de longueur minimale est alors $[a_0Y, b_0Y]$ où $b_0 = a_0\sqrt{\frac{2}{(\alpha-2)a_0^2+4a_0-2}}$. Malheureusement, a_0 n'a pas de forme analytique. On poursuit en R avec $\alpha = 0.1$ pour obtenir une approximation numérique :

```
alpha <- 0.05
intervalle <- c(max(1, ((2-sqrt(2*alpha))/(2-alpha))), min(2,
   ((2+sqrt(2*alpha))/(2-alpha))))

g <- function(a){
   return (sqrt(2)*a/sqrt((alpha-2)*a**2+4*a-2) - a)
}

a_0 <- optimize(f = g, interval = intervalle)$minimum
b_0 <- g(a_0) + a_0

print(c(a_0,b_0))
print(b_0-a_0)
```

La réponse est :

```
[1] 1.011526 4.477954
[1] 3.466428
```

Alors, si $\alpha = 0.1$, le choix optimal est approximativement $a_0 = 1.011526$ et $b_0 = 4.477954$. ////